Caso 03. Modelo de Redes Neuronales

María González García

19 de mayo del 2025

UAX Universidad Alfonso X el Sabio

UAX Universidad Alfonso X el Sabio

Del dato clínico a la decisión crítica

¿Podemos anticipar el riesgo vital antes de que sea visible?

Desafío Actual: Gestión de información clínica crítica.

En la práctica médica diaria, los profesionales deben priorizar pacientes con rapidez, pero la complejidad y el volumen de datos dificultan identificar quién está realmente en riesgo.

Volumen de datos creciente
Los hospitales generan miles de datos por paciente, cada día.

→

Datos heterogéneos y desconectados
Información clínica, social, económica y genética no siempre integrada

→

Riesgos invisibles al ojo clínico
Muchos pacientes críticos no muestran signos evidentes en fases tempranas.

→

Falta de herramientas predictivas eficaces
No basta con intuición médica: hacen falta modelos que ayuden a anticipar.

Contexto del problema.

La falta de predicción temprana compromete la atención médica y los recursos sanitarios.

Desafíos del entorno hospitalario:

- Decisiones críticas bajo presión
- Recursos limitados
- Importancia de priorizar sin margen de error

Limitaciones del enfoque tradicional:

- Análisis manual poco eficiente
- Patrones complejos difíciles de detectar
- Posibles errores al evaluar riesgo real

Por su parte, Mohammad Lotfollahi, del Wellcome Sanger Institute, explica que, al igual que las personas comparten información en sus redes sociales, las células se comunican a través de sus características, formando redes locales. «NicheCompass es el **primer modelo de IA capaz de interpretar estas redes**, lo que podría impactar directamente en la vida de los pacientes, al identificar el origen de problemas de salud y predecir cómo podrían responder a tratamientos».

Basado en prácticas reconocidas por ABC Salud: *"Una IA visualiza la red social de las células y personaliza la terapia en cáncer" (ABC Salud, 2025).*

Solución propuesta: IA Clínica Predictiva

Uso de una red neuronal con datos clínicos para predecir la supervivencia del paciente y asistir en decisiones médicas críticas.

Red Neuronal Predictiva
Modelo entrenado con datos reales para anticipar el riesgo de no supervivencia

- Integra datos clínicos, genéticos y sociales de cada paciente
- Aprende patrones de riesgo no evidentes para priorizar casos críticos
- Apoya decisiones médicas con predicciones personalizadas y útiles

Una IA visualiza la red social de las células y personaliza la terapia en cáncer

NicheCompass es un modelo de IA de aprendizaje profundo que estudia la comunicación célula a célula, aprendiendo cómo interactúan las células y alineándolas con redes similares, formando vecindarios en los tejidos a través de características compartidas.

Arquitectura de la solución predictiva

Objetivo Principal: Diseñar, entrenar y evaluar un modelo de red neuronal capaz de predecir la supervivencia de pacientes, utilizando un conjunto amplio y diverso de variables clínicas, genéticas, bioquímicas, sociales y económicas.

→ *Meta: **Recall elevado,** priorizando la identificación de pacientes con alta probabilidad de no supervivencia y minimizando falsos negativos (pacientes en riesgo que no son detectados).*
Este enfoque se justifica porque:

- *El dataset está altamente desbalanceado (solo ~10 % no sobreviven).*
- *En medicina, el error más crítico es no detectar a tiempo un caso grave.*
- *El modelo no predice muerte, sino que alerta sobre perfiles de riesgo para facilitar una atención médica más precisa.*

Metodología Aplicada.

Integración de datos — **Variables clínicas, bioquímicas, genéticas y socioeconómicas desde múltiples tablas.**

Preprocesamiento estructurado — **Normalización de variables, codificación categórica correcta, limpieza de datos.**

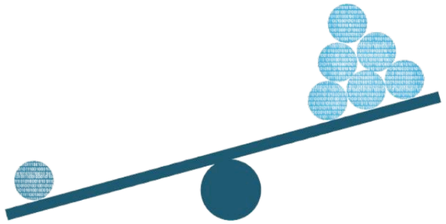

Selección de variables — **Modelo Random Forest inicial para identificar las columnas más relevantes.**

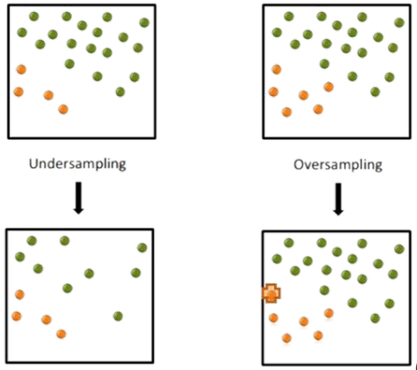

Abordaje del desbalance de clases — **Oversampling, Undersampling, Pesado de clases, Estrategias combinadas**

Diseño de la red neuronal — **Arquitectura feedforward con regularización, dropout y ajuste del umbral**

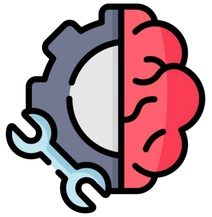

Evaluación y benchmarking — **Métricas clínicas clave y comparación con modelos clásicos.**

Interpretabilidad — **Técnica SHAP: Predicciones y facilitar comprensión clínica.**

Resultados: Rendimiento y elección del modelo final

Métricas de Desempeño: No Sobrevive.

- **Recall**: 0.70
- **Precisión**: 0.31
- **F1-score**: 0.42
- **Macro F1-score:** 0.65
- **Accuracy global:** 76%

(Threshold ajustado a 0.6 para priorizar recall en clase 0)

Insight clave.

→ El modelo es más valioso cuando prioriza la **detección de riesgo real**, no solo el acierto global.
→ **Detectar a tiempo** es más importante que acertar siempre.
→ Aceptar algunas falsas alarmas es preferible a no avisar ante un caso grave.

Técnicas probadas contra el desbalance.

- **Class Weight:** Ajuste de pesos por clase
- **SMOTE:** Generación de ejemplos sintéticos
- **Submuestreo (NCR):** Eliminar exceso de clase mayoritaria
- **Combinaciones:** NCR + Class Weight

Modelo ganador: Class weight

Estabilidad, generalización y fiabilidad clínica.
→ Curvas de entrenamiento más limpias y suaves.
→ Menos diferencia entre entrenamiento y validación.
→ Evita el sobreajuste mejor que otras técnicas.
→ Aunque las métricas son similares, es el más consistente y controlado, ideal para medicina.

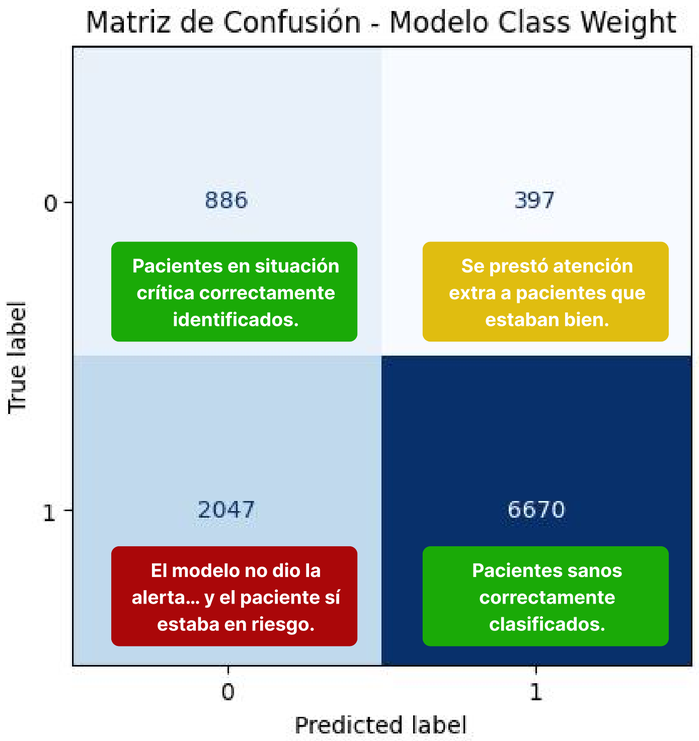

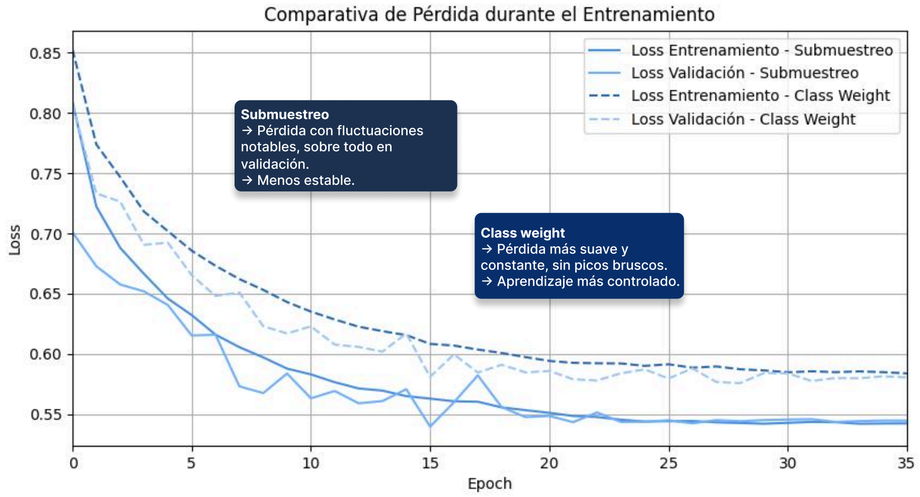

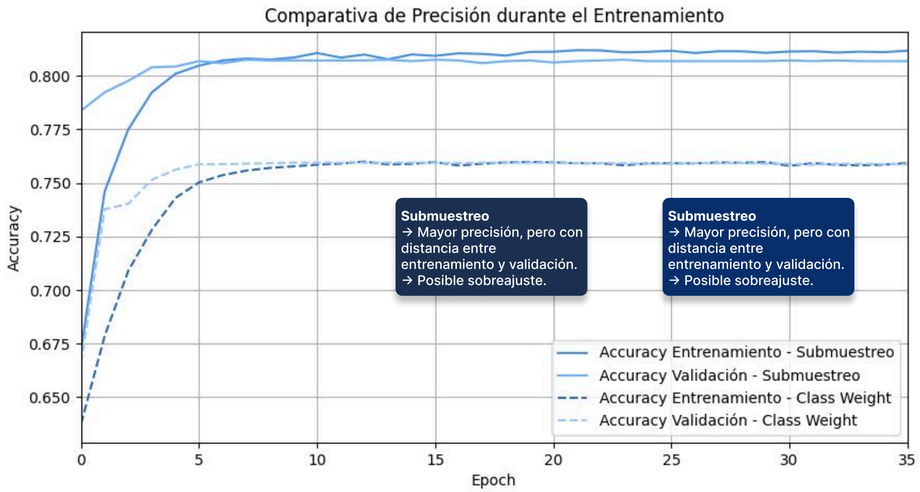

Resultados clave.

Detecta pacientes en riesgo
El modelo identifica a 7 de cada 10 pacientes que están realmente en peligro.

Acepta falsas alarmas controladas
Es mejor avisar por precaución aunque algunos estén bien.

Evita errores graves
Reduce los casos donde no se actuaría y sí era necesario.

Buen rendimiento global
El modelo acierta en 3 de cada 4 pacientes en general.

UAX Universidad Alfonso X el Sabio

Más allá de los números: Confiable, explicable y útil

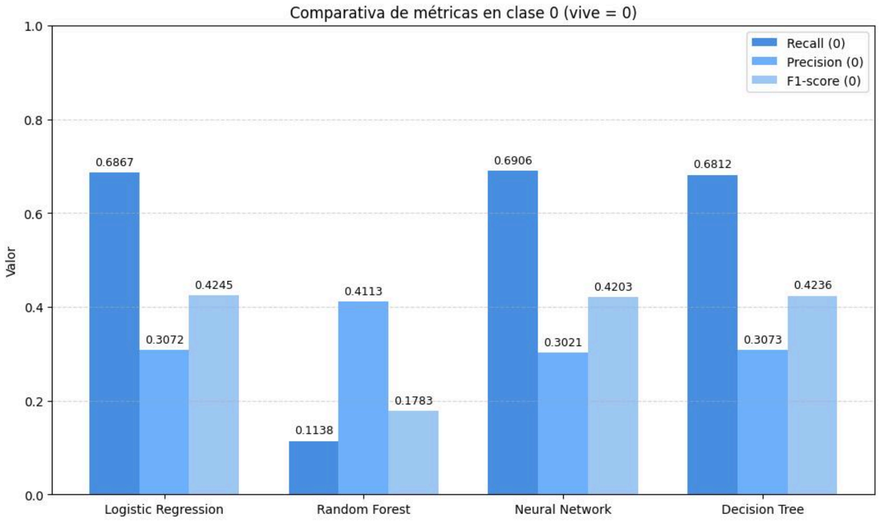

Comparación con modelos clásicos.

Todos tienen métricas similares, pero la red neuronal mostró ser más robusta.

- Curvas más **estables y predecibles** durante el entrenamiento.
- Mejor **equilibrio entre sensibilidad y control**.
- **Generaliza mejor** a nuevos datos.
- Ideal en medicina, donde lo importante es **detectar a tiempo**, no solo acertar más.

Interpretabilidad clínica del modelo con SHAP.

Grupo 1 – Biomarcadores clínicos

- Hemoglobina alta → + Supervivencia
- Colesterol alto → + Supervivencia
- Triglicéridos altos → + leve
- Creatinina alta → – Supervivencia
- Glucosa alta → – Supervivencia (riesgo)
- Leucocitos y plaquetas → Impacto neutro o débil

Grupo 3 – Variables sociodemográficas

- Actividad física alta → + Supervivencia
- Nivel educativo alto → + leve
- Edad alta → + (asociada a perfiles clínicos más estables, no a mayor riesgo)
- Sexo → Impacto neutro

El modelo reconoce que estilo de vida y educación influyen positivamente.

Valor aplicado en salud

- Ayuda a **priorizar pacientes en riesgo** desde el primer contacto.
- Aporta una **alerta temprana** basada en datos objetivos.
- **Reduce errores críticos** como pasar por alto un perfil grave.
- Es **interpretable y confiable**, útil como apoyo clínico, no sustitución.

Grupo 2 – Enfermedades diagnosticadas

- Enfermedad cardíaca → — Supervivencia **(Fuerte impacto)**
- Cáncer → – Supervivencia (Moderado)

El modelo detecta correctamente enfermedades graves como factores de alto riesgo.

Grupo 4 – Factores económicos

- Gastos en salud altos → – Supervivencia (Gravedad clínica)
- Ingresos altos → + Supervivencia (Acceso y estabilidad)

El modelo aprende que el contexto económico puede reflejar salud o vulnerabilidad.

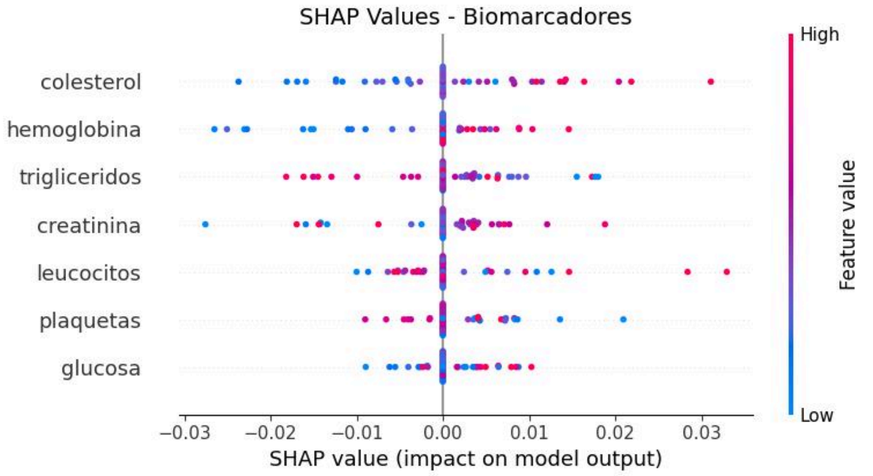

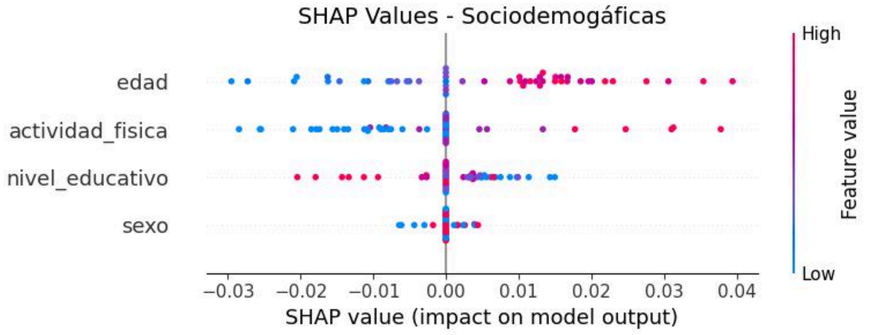

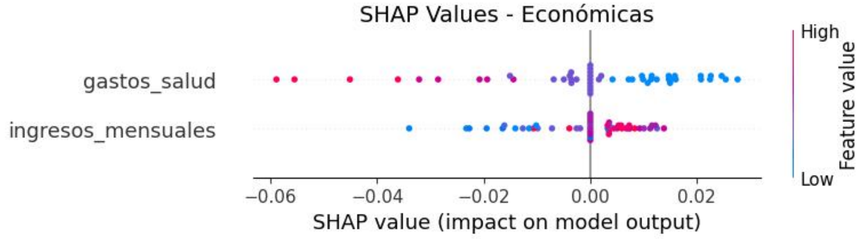

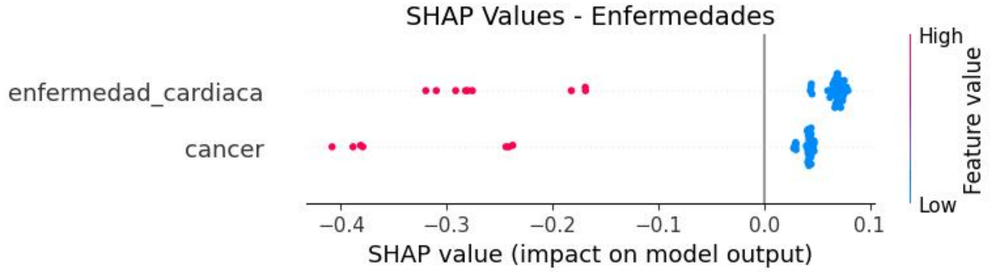

Un modelo listo para impactar en la vida real

Aplicación clínica realista.

El modelo ya demuestra utilidad como herramienta de apoyo clínico en:

- **Pre-triaje automatizado** → Priorizar pacientes en riesgo desde el ingreso.
- **Seguimiento de crónicos complejos** → Aporta una segunda opinión algorítmica.
- **Entornos comunitarios o vulnerables** → Incorpora factores sociales y económicos.
- **Medicina personalizada** → Gracias a SHAP, permite explicar cada decisión al paciente.

No sustituye al profesional, pero lo refuerza con datos y explicaciones.

Propuesta: VIDE – Visor Inteligente de Decisiones de Evaluación.

Una herramienta digital que transforma el modelo en un visor clínico explicable y accionable.

Se conecta al historial médico y muestra:

- Nivel de riesgo (bajo, medio, alto).
- Factores clave detectados por el modelo.
- Explicación visual con SHAP y sugerencias clínicas.

Pensado para:

- Consultas médicas.
- Urgencias.
- Programas de prevención.

Limitaciones actuales

- Dataset **desbalanceado**, con pocos casos críticos.
- Datos **estáticos**, sin evolución temporal.
- **Falta de variables clínicas complementarias** (síntomas, historial farmacológico, evolución).

Estos retos limitan el alcance actual, pero son abordables.

Roadmap de mejora.

Optimización técnica

- Ajustes finos del modelo y técnicas de balanceo.
- Validación cruzada más robusta.

Validación clínica

- Pruebas con nuevos pacientes reales.
- Revisión por médicos de errores clave.

Integración operativa

- Interfaz integrada en la historia clínica.
- Panel de control médico + explicación por SHAP.
- Evaluación ética y formación del personal.

UAX Universidad Alfonso X el Sabio

¡Gracias por su Atención!

Soy Innovación
Soy Maker
Soy UAX

Para más información y acceso al código:
GitHub - IA Redes